BIG DATA · UDEM

Big Data e Ingeniería de Datos

Clase 4 · De archivos a tablas, y Taller 1

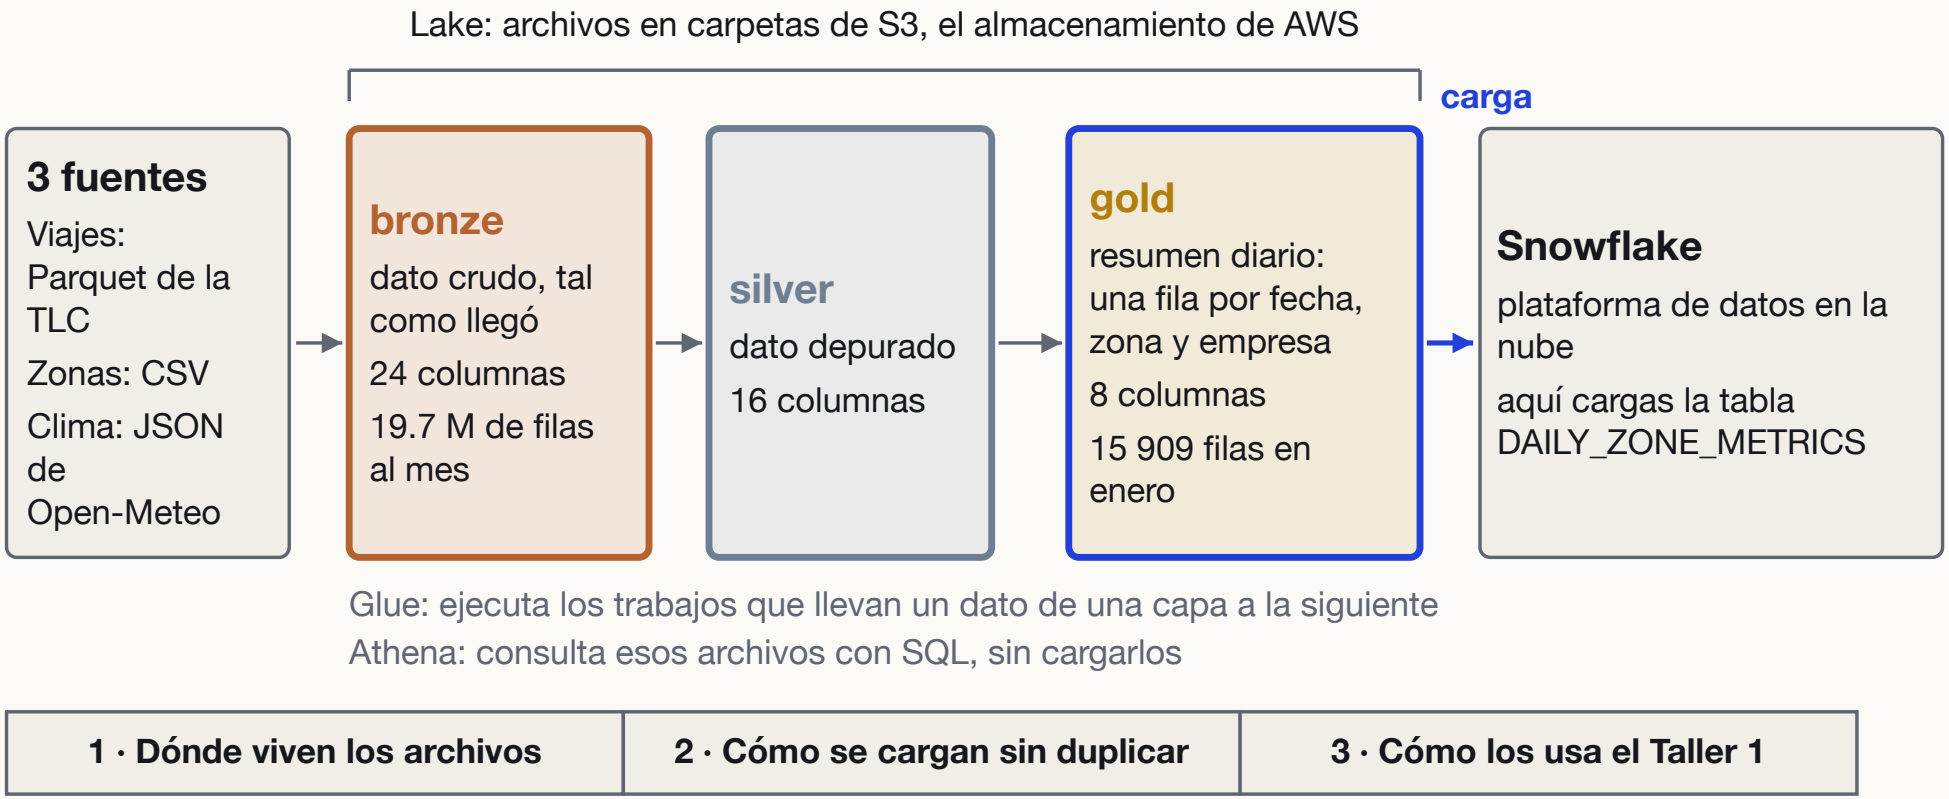
Posgrado · UdeM · 10 nov 2026

239.5 M

viajes de Uber y Lyft en NYC, 2024. Pregunta del curso: ¿la lluvia cambia los viajes en NYC? Se cruzan con clima y zonas.

Medición propia, 1 nov. 2026

Los viajes salen de tres fuentes, pasan por tres capas de archivos y llegan a Snowflake



TLC: el regulador de taxis y plataformas de NYC. Gold: el resumen diario.

PROBLEMA

¿Cómo llegan los viajes a Snowflake sin duplicarse, si primero son archivos?

Cargar enero dos veces sin control deja 31 818 filas, no 15 909, y no avisa.

Para recorrer un lake, creas el tuyo en AWS y en Snowflake

Code Editor

1. Paso 10: cd ~/bigdata; make deploy.
2. Crea lake, Glue y Athena: «Deploy completado».
3. Paso 11: cd ~/bigdata; make snowflake; escribe yes.
4. Crea warehouse y base: «Conexión … guardada».

Descargas el año de viajes con Glue; mientras, vemos cómo se ordena un lake

Code Editor

1. Paso 12: cd ~/bigdata; make muestra.
2. Glue baja el año (5.4 GB) a bronze y una muestra (clase 5).
3. Tras unos 5 min, ves «muestra OK».

Parquet guarda por columnas: de 24 por viaje, silver lee 15 y guarda 16 con zona y clima

	CSV	Parquet
Orden	Por filas	Por columnas
Una columna	Lee todo	Lee solo esa
Tipos	Texto	Fecha, entero, decimal

Capas y carpetas por mes: un mes de bronze pesa 450 MB; tres de gold, 641 KB

Tu lake de AWS tras make muestra

Hoy solo existen bronze/ y muestra/; silver/ y gold/ los escribe el pipeline (clase 5).

`bigdata-lake-<cuenta>-us-east-2/`
bucket: carpeta de nivel superior de S3

- **`bronze/`**
  crudo · 24 columnas · ≈ 450 MB por mes
- **`muestra/`**
  muestra pequeña del año, para la clase 5
- **`silver/pickup_date=2024-01-01/ …`**
  depurado · 16 columnas · una carpeta por día
- **`gold/daily_zone_metrics/mes=2024-01/ …`**
  resumen · 8 columnas · una carpeta por mes

carpeta = clave=valor

Paquete público del curso: el gold de enero a marzo, igual para todos

`bigdata-udem-2026-publico/paquete/gold/daily_zone_metrics/`

`mes=2024-01/`	2 archivos .parquet
`mes=2024-02/`	2 archivos .parquet
`mes=2024-03/`	2 archivos .parquet

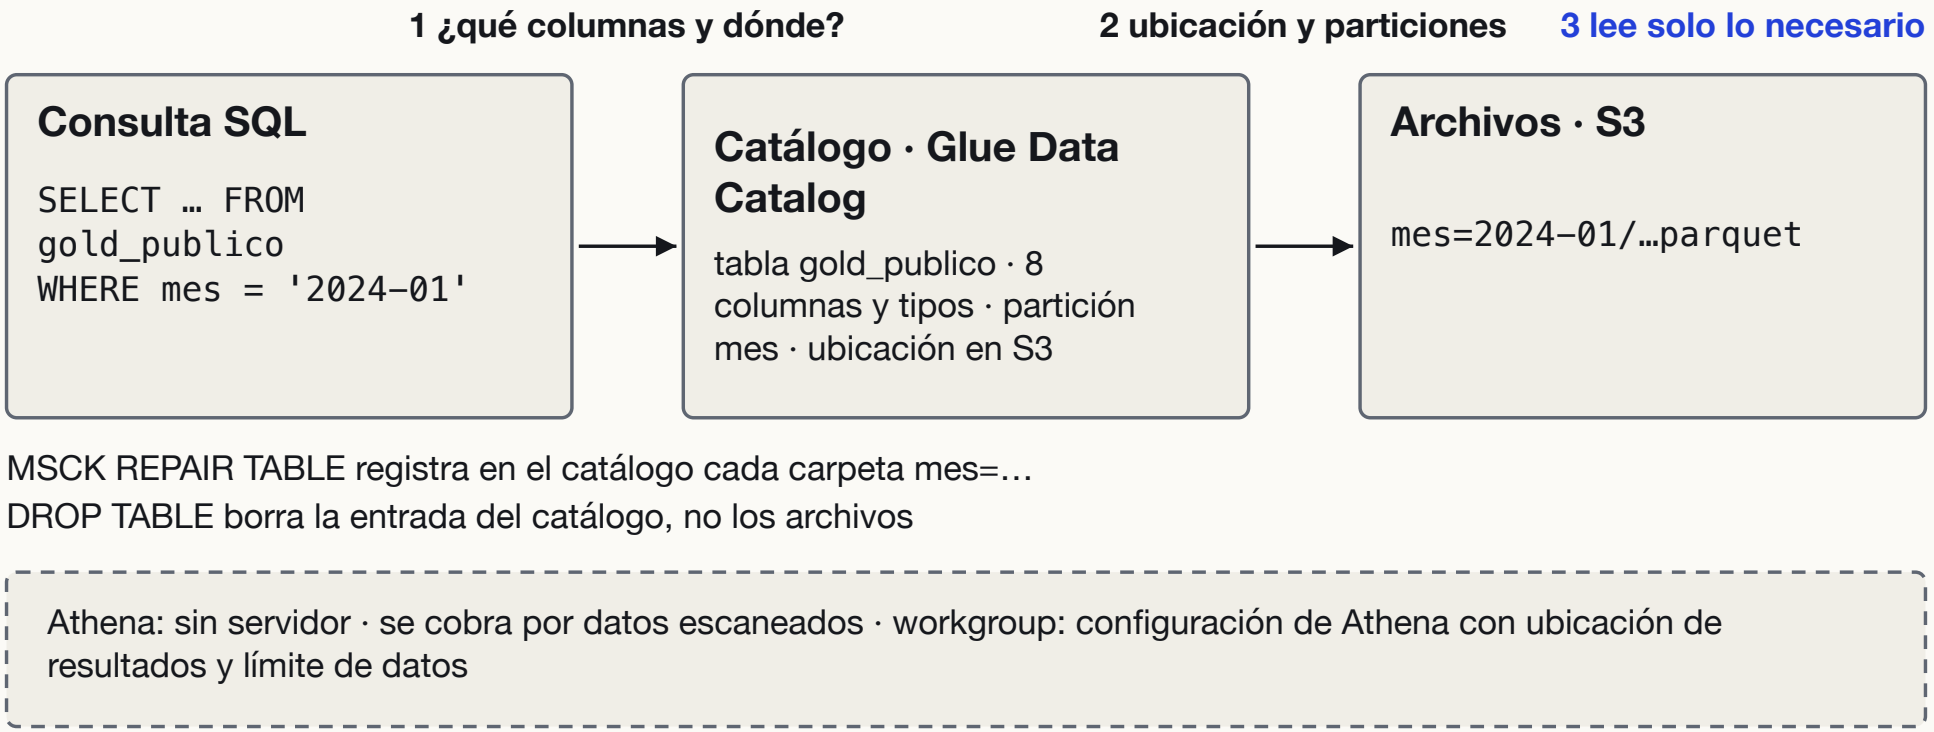
WHERE mes = '2024-01' lee solo esta carpeta (Athena)

Total: 6 archivos · 641 KB

La columna fecha va también dentro del Parquet; mes solo está en el nombre de la carpeta.

Partición: carpeta llamada clave=valor; filtrar por mes salta las demás.

Los archivos no traen su tabla: un catálogo registra columnas, tipos y particiones para Athena



Athena: SQL sobre archivos de S3. Glue: jobs que transforman y catálogo que describe.

Athena necesita región, workgroup y base; make deploy creó los dos últimos

Consola AWS

1. Arriba a la derecha: región us-east-2 (Ohio).
2. Athena, Query editor.
3. Workgroup bigdata-wg (tope de 1 GB).
4. Base bigdata_lake; si falta, CREATE DATABASE IF NOT EXISTS bigdata_lake;

La tabla externa declara columnas y ruta del gold; los archivos no se copian

```
CREATE EXTERNAL TABLE IF NOT EXISTS bigdata_lake.gold_publico (
  fecha date, zona string, empresa string, viajes bigint,
  ingreso_total double, propina_promedio double,
  distancia_promedio double, lluvia_mm double)
PARTITIONED BY (mes string)
STORED AS PARQUET
LOCATION 's3://bigdata-udem-2026-publico/paquete/gold/daily_zone_metrics/';
```

Catálogo apunta a archivos que Athena no administra; mes sale de las carpetas mes=…. En Snowflake será DAILY_ZONE_METRICS. Debes ver «Query successful». Completo en athena_demo.sql.

Las particiones se registran con MSCK REPAIR, y Q1 devuelve los tres meses del gold

```
SELECT COUNT(*) FROM bigdata_lake.gold_publico;  -- 0: sin particiones
MSCK REPAIR TABLE bigdata_lake.gold_publico;
SHOW PARTITIONS bigdata_lake.gold_publico;  -- 3 particiones
-- Q1: las 8 columnas de las 3 carpetas
SELECT mes, COUNT(*) AS filas, SUM(viajes) AS viajes,
  SUM(ingreso_total) AS ingreso, AVG(propina_promedio) AS propina,
  AVG(distancia_promedio) AS distancia, MAX(lluvia_mm) AS lluvia,
  COUNT(DISTINCT zona) AS zonas, COUNT(DISTINCT empresa) AS empresas,
  MIN(fecha) AS desde
FROM bigdata_lake.gold_publico GROUP BY mes ORDER BY mes;
```

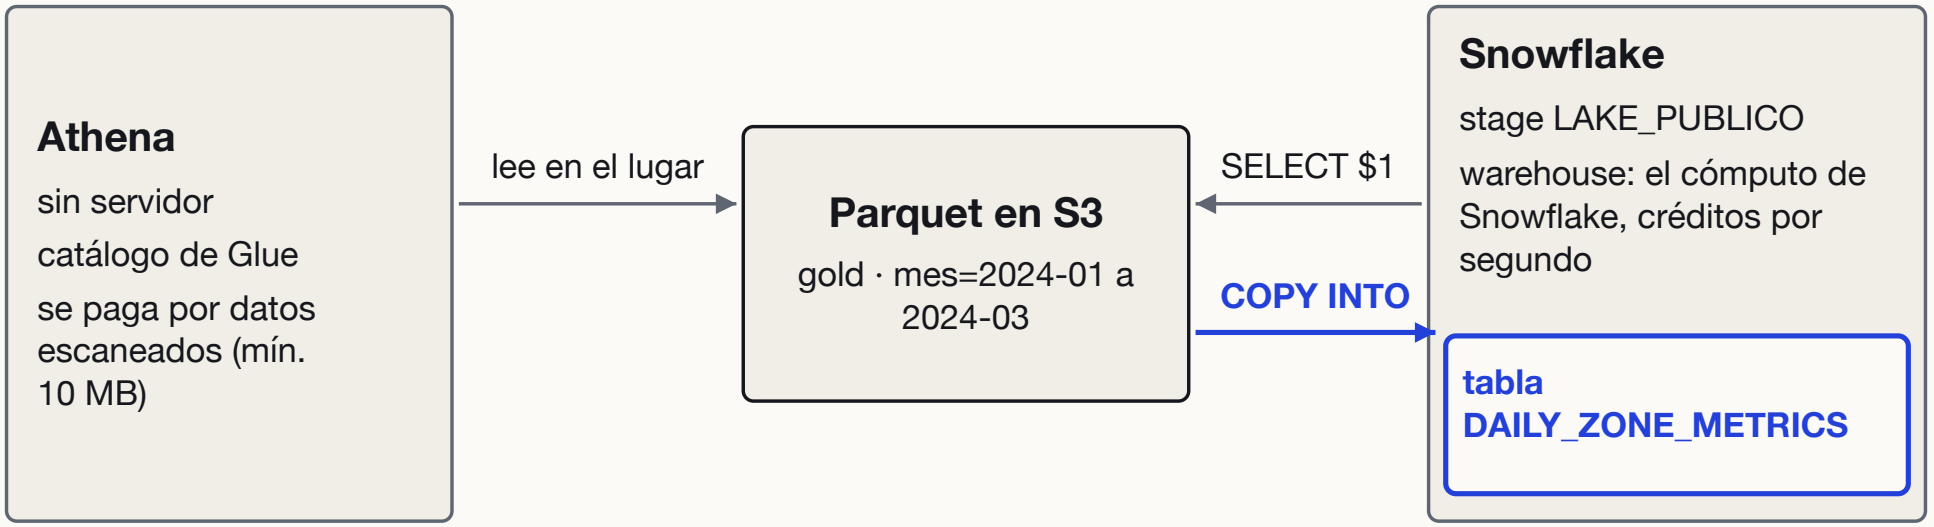
Una sentencia por Run. Verás 0; tres particiones; Q1: 15 909, 14 889 y 15 917 filas por mes. Data scanned: 643 KB. Completo en athena_demo.sql.

Con US$5 por TB y mínimo de 10 MB, Q2 escanea menos que Q1 pero paga igual

```sql
-- Q2: 1 columna, 1 carpeta (mes=2024-01)
SELECT SUM(viajes) AS viajes
FROM bigdata_lake.gold_publico
WHERE mes = '2024-01';
```

Verás 19 650 023. Data scanned, en la barra bajo el editor: 48 KB. Q1 y Q2 pagan 10 MB, unos US$0.00005. Precio: aws.amazon.com/athena/pricing.

Dos motores leen los mismos archivos: Athena sin servidor y Snowflake con un stage, sin copiar nada todavía



Stage: ubicación de archivos, aquí S3, que Snowflake lee sin copiarlos.

Cargar se paga una vez: transformar sobre archivos, 172 s; sobre la tabla, 14 s

Mes crudo, 19.7 M viajes	Archivos	Tabla cargada
Cada corrida	172 s	14 s
Carga única (subida local)	Nada	268 s
Gold, 641 KB, estimado	Segundos	Segundos

COPY INTO recuerda lo cargado: repetirlo agrega 0 filas, salvo con FORCE

```
CREATE OR REPLACE FILE FORMAT PARQUET_PUB TYPE = PARQUET;
CREATE OR REPLACE STAGE LAKE_PUBLICO
  URL = 's3://bigdata-udem-2026-publico/paquete/gold/daily_zone_metrics/'
  FILE_FORMAT = PARQUET_PUB;

COPY INTO DAILY_ZONE_METRICS
FROM @LAKE_PUBLICO
PATTERN = '.*[.]parquet'
MATCH_BY_COLUMN_NAME = CASE_INSENSITIVE;
```

Snowflake recuerda por tabla qué archivos cargó (64 días): repetir el COPY da «Copy executed with 0 files processed.». FORCE = TRUE recarga y duplica. PATTERN elige archivos; MATCH_BY_COLUMN_NAME asigna columnas por nombre.

Lab 4: cargas el gold sin duplicar y verificas conteos

Snowsight

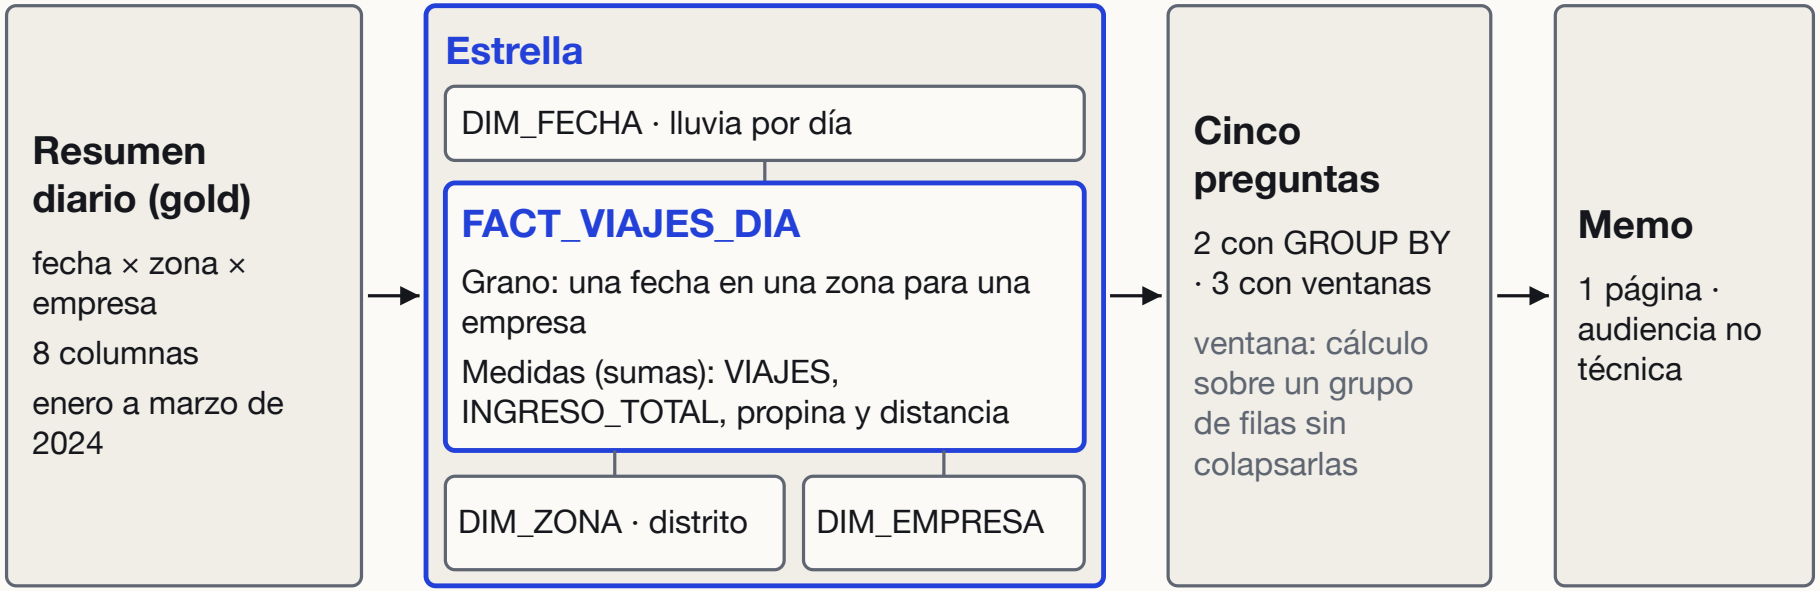
1. Snowsight (editor web): pega lab4.sql, corre Paso 0.
2. E1-E4 (ejercicios): COPY INTO; 46 715 filas.
3. E5: repite el COPY; 0 filas.
4. E6: dim_zona y festivos_2024.
5. lab4_verificacion.sql, Run All: 6 de 6.

514

DESCANSO

¿Cómo se suma la lluvia si el resumen diario la repite en más de 500 filas por día?

Taller 1: tu equipo diseña una estrella, la carga y responde cinco preguntas



Ejemplo de fila del hecho: 2024-01-24 · JFK Airport · Lyft · 1 965 viajes · 153 097.03

El gold trae promedios: la estrella guarda sumas (promedio × viajes) o pondera por viajes.

Estrella: hechos (medidas) y dimensiones (contexto). Grano: qué es una fila del hecho. Enunciado: curso/clase04/taller1/README.md.

Dos trampas: la lluvia se cuenta una vez por día y el promedio se pondera por viajes

Lluvia repetida

2024-01-10 · 514 filas · LLUVIA_MM = 21.7 en cada una

✗ ~~SUM(LLUVIA_MM) = 11 153.8~~

✗ COUNT(*) = 514 → son filas, no días

✓ **MAX(LLUVIA_MM) por FECHA = 21.7**

Cada día tiene entre 510 y 516 filas (enero a marzo).

Promedio de un grupo

JFK Airport · 2024-01-24

Lyft · 1 965 viajes · propina 4.05
Uber · 7 265 viajes · propina 3.76

✗ AVG simple = 3.905

✓ **SUM(propina × viajes) / SUM(viajes) = 3.82**

Diferencia: 2.2 %

El gold ya redondeó cada promedio a 2 decimales.

Promedio ponderado: multiplicar cada promedio por sus viajes y dividir entre el total de viajes.

Los decimales no se comparan con =, y dos nombres de zona repetidos duplican filas al unir

Redondeo

✗ `0.1 + 0.2 = 0.3 → FALSE (FLOAT)`

✓ **`ROUND(0.1 + 0.2, 2) = 0.3 → TRUE`**

Compara con ROUND(x, 2) o ABS(a – b) < 0.01

INGRESO_TOTAL y los promedios se redondean a 2 decimales en gold.

Nombre de zona repetido

gold · ZONA = «Corona» · 182 filas

↓ unión por nombre

DIM_ZONA · «Corona» · 2 filas (LocationID 56 y 57)

↓

resultado · 364 filas · SUM(VIAJES) × 2

En total: +196 filas y +184 265 viajes (0.3 %)

Solución: el gold trae el nombre, no el LocationID; une con una fila por nombre (262 zonas distintas).

Control: GROUP BY ZONA HAVING COUNT(*) > 1; cuenta las filas antes y después de unir.

Join: unir tablas por una columna común; si la clave se repite, duplica filas.

Hay tres casos con el mismo trabajo técnico; tu equipo elige uno y responde cinco preguntas

A · Competencia entre plataformas

¿Hay concentración por zona?

A1 Ingresos y viajes por empresa-mes
GROUP BY

A2 Propina ponderada por empresa
SUM/SUM

A3 Top-3 zonas por empresa
RANK + QUALIFY

A4 Cuota de mercado por zona y mes
SUM OVER

A5 Variación mensual de la cuota
LAG

B · Clima y festivos

¿Cuándo se dispara la demanda?

B1 Viajes por día: lluvia o seco
GROUP BY

B2 Saltos de más de 50 %
LAG

B3 Media móvil de 7 días por zona
AVG OVER

B4 Top-3 zonas por día de semana
RANK + QUALIFY

B5 Festivo frente a día típico
GROUP BY

C · Aeropuertos y distritos

¿Dónde se concentra el servicio?

C1 Viajes por distrito y mes
GROUP BY

C2 Ranking de zonas por distrito
RANK

C3 Propina ponderada por distrito
SUM/SUM

C4 Media móvil 7 días: aeropuertos
AVG OVER

C5 Participación en el distrito y LAG
SUM OVER

RANK: puesto dentro de un grupo · QUALIFY: filtra una ventana · LAG: valor de la fila anterior · OVER: ventana que no colapsa filas

A usa solo el gold. B suma festivos. C suma dim_zona; borough: distrito de NYC.

Siete archivos forman el núcleo; súbelos a taller1/ (paso a paso: taller1/README.md)

Archivo	Contenido
01_estrella.sql, diagrama.md	Estrella
02_carga.sql	Carga y conteo
03_preguntas.sql	Cinco preguntas
04_chequeos.sql	Filas, grano, sin pareja, viajes
memo.md	Una página
costos.md	Créditos y Query Profile (desglose por operador)

Preguntas y estrella suman 40 de los 85 puntos del núcleo; los retos opcionales añaden hasta 15

Criterio	Pts	Criterio	Pts
Preguntas	22	Datos cargados	8
Estrella	18	Equipo	8
Técnica SQL	15	Costo	5
Memo	9	Retos (extra)	15

Cuatro roles reparten el trabajo del equipo y todos ejecutan SQL en su propia cuenta

Rol	Responde por
Analista	Pregunta, definiciones, memo
Modelador	Estrella y consultas
Ingeniero de datos	Carga y chequeos
Calidad y costos	Controles y costos.md

Cada equipo trabaja en un fork, copia del repositorio del curso, que aloja un integrante: el anfitrión

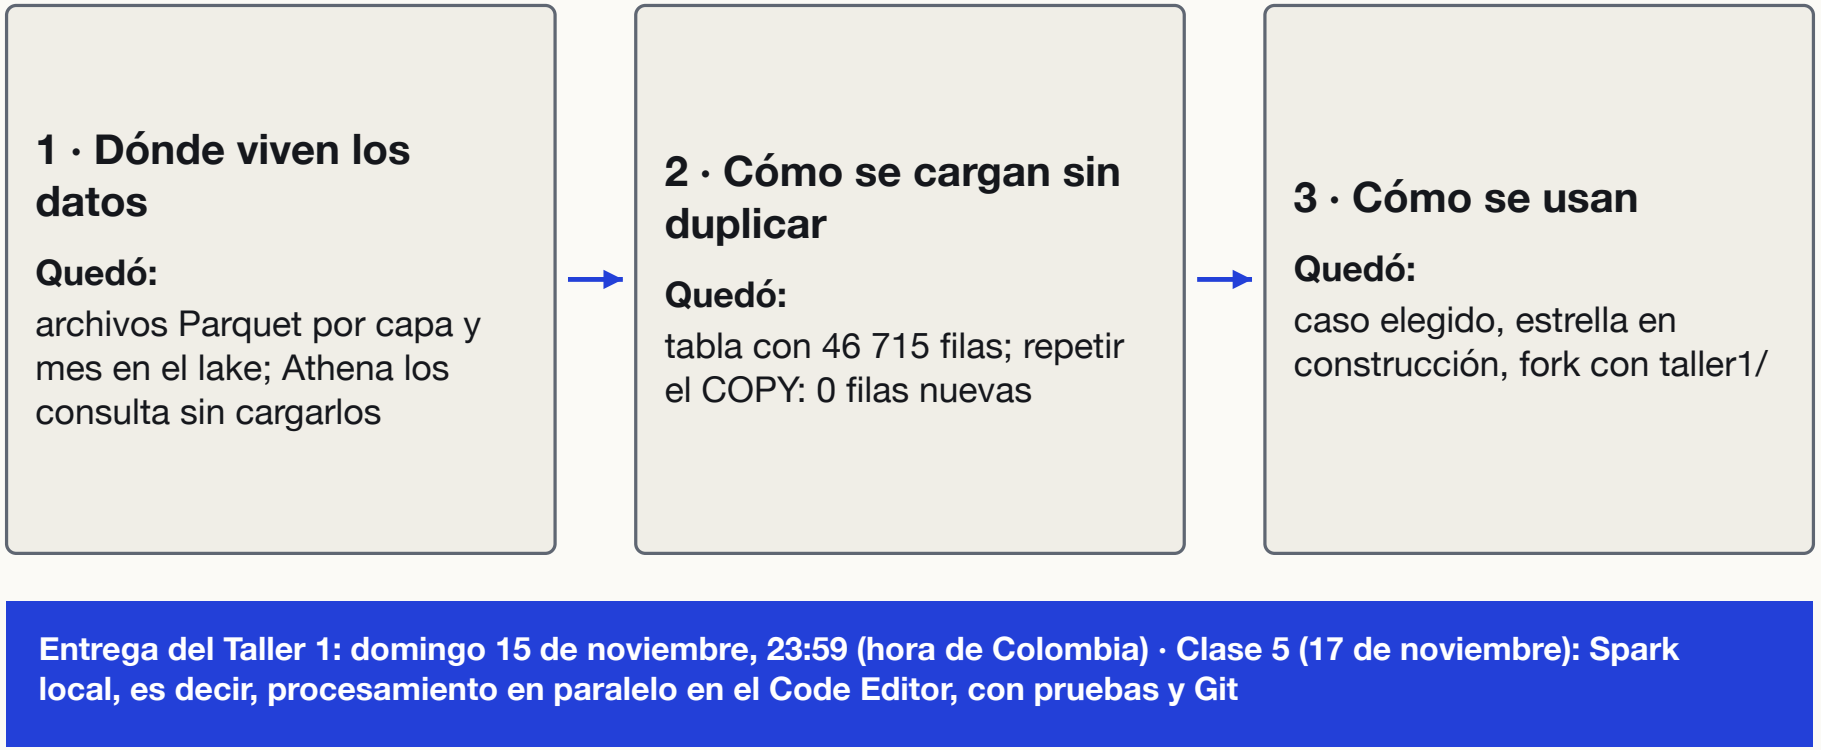
GitHub

1. Ubica tu equipo; elijan anfitrión.
2. Anfitrión: Settings, Collaborators, invita.
3. Crea taller1/README.md: integrantes, caso, roles.
4. Cada quien: esquema CURSO.T1.
5. Paso a paso: curso/clase04/taller1/README.md.

Cuatro hitos y un cierre ordenan 95 minutos de taller en clase

Min	Debe existir
15	Caso y roles definidos
35	Estrella cargada (anfitrión)
65	Preguntas 1 a 3 con resultado
85	Preguntas 4 y 5; chequeos
95	Todo subido; pendientes asignados

Hoy cargaste el gold sin duplicar; entrega el Taller 1 el 15 de noviembre



Entrega: release t1-entrega (versión etiquetada del fork del anfitrión en GitHub), domingo 15 nov., 23:59, hora de Colombia.